概述

爬虫，应该称为网络爬虫，也叫网页蜘蛛、网络机器人、网络蚂蚁等。
搜索引擎，就是网络爬虫的应用者。
为什么到了今天，反而这个词汇被频繁的提起呢？有搜索引擎不就够了吗？
实际上，大数据时代的到了，所有的企业都希望通过海量数据发现其中的价值。
所以，需要爬取对特定网站、特定类别的数据，而搜索引擎不能提供这样的功能，因此，需要自己开发爬虫来解决。

爬虫分类

通用爬虫

常见就是搜索引擎，无差别的收集数据、存储，提取关键字，构建索引库，给用户提供搜索接口。

爬取一般流程

1. 初始一批URL，将这些URL放到待爬取队列
2. 从队列取出这些URL，通过DNS解析IP，对IP对应的站点下载HTML页面，保存到本地服务器中，爬取完的URL放到已爬取队列。
3. 分析这些网页内容，找出网页里面的其他关心的URL链接，继续执行第2步，直到爬取条件结束。

搜索引擎如何获取一个新网站的URL

- 新网站主动提交给搜索引擎
- 通过其它网站页面中设置的外链
- 搜索引擎和DNS服务商合作，获取最新收录的网站

聚焦爬虫

有针对性的编写特定领域数据的爬取程序，针对某些类别数据采集的爬虫，是面向主题的爬虫

Robots协议

指定一个robots.txt文件，告诉爬虫引擎什么可以爬取。

淘宝 http://www.taobao.com/robots.txt

```
User-agent:  Baiduspider
Allow:  /article
Allow:  /oshtml
Allow:  /ershou
Disallow:  /product/
Disallow:  /

User-Agent:  Googlebot
Allow:  /article
```

```
Allow:  /oshtml
Allow:  /product
Allow:  /spu
Allow:  /dianpu
Allow:  /oversea
Allow:  /list
Allow:  /ershou
Disallow:  /

User-agent:  Bingbot
Allow:  /article
Allow:  /oshtml
Allow:  /product
Allow:  /spu
Allow:  /dianpu
Allow:  /oversea
Allow:  /list
Allow:  /ershou
Disallow:  /

User-Agent:  Yahoo!  Slurp
Allow:  /product
Allow:  /spu
Allow:  /dianpu
Allow:  /oversea
Allow:  /list
Allow:  /ershou
Disallow:  /

User-Agent:  *
Disallow:  /
```

马蜂窝 http://www.mafengwo.cn/robots.txt

```
User-agent: *
Disallow: /music/
Disallow: /travel-photos-albums/
Disallow: /lushu/
Disallow: /hc/
Disallow: /hb/
Disallow: /insure/show.php
Disallow: /myvisa/index.php
Disallow: /booking/discount_booking.php
Disallow: /secrect/
Disallow: /gonglve/visa.php
Disallow: /gonglve/visa_info.php
Disallow: /gonglve/visa_case.php
Disallow: /gonglve/visa_seat.php
Disallow: /gonglve/visa_readme.php
Disallow: /gonglve/insure.php
Disallow: /gonglve/insurer.php
```

```
Disallow: /gonglve/hotel.php
Disallow: /gonglve/hotel_list.php
Disallow: /gonglve/flight.php
Disallow: /gonglve/traffic.php
Disallow: /gonglve/scenery.php
Disallow: /insure/tips-*.html
Disallow: /skb-i/
Disallow: /weng/pin.php?tag=*
Disallow: /rank/
Disallow: /hotel/s.php
Disallow: /photo/mdd/*_*.html
Disallow: /photo/poi/
Disallow: /hotel/*/?sFrom=*
Disallow: /weng/
Disallow: /order_center/
Disallow: /hotel_zx/order/detail.php

Sitemap: http://www.mafengwo.cn/sitemapIndex.xml
```

其它爬虫，不允许爬取
User-Agent: *
Disallow: /

这是一个君子协定，“爬亦有道”

这个协议为了让搜索引擎更有效率搜索自己内容，提供了如Sitemap这样的文件。
这个文件禁止抓取的往往又是可能我们感兴趣的内容，它反而泄露了这些地址。

HTTP请求和响应处理

其实爬取网页就是通过HTTP协议访问网页，不过通过浏览器访问往往是人的行为，把这种行为变成使用程序来访问。

urllib包

urllib是标准库，它一个工具包模块，包含下面模块来处理url：

- urllib.request 用于打开和读写url
- urllib.error 包含了由urllib.request引起的异常
- urllib.parse 用于解析url
- urllib.robotparser 分析robots.txt 文件

Python2中提供了urllib和urllib2。urllib提供较为底层的接口，urllib2对urllib进行了进一步封装。Python3中将urllib合并到了urllib2中，并只提供了标准库urllib包。

urllib.request模块

模块定义了在基本和摘要式身份验证、 重定向、 cookies等应用中打开 Url (主要是 HTTP) 的函数和类。

urlopen方法

`urlopen(url, data=None)`
url是链接地址字符串，或请求对象。
data提交的数据，如果data为None发起GET请求，否则发起POST请求。见`urllib.request.Request#get_method`
返回http.client.HTTPResponse类的响应对象，这是一个类文件对象。

```
from urllib.request import urlopen


# 打开一个url返回一个响应对象，类文件对象
# 下面的链接访问后会有跳转
response = urlopen('http://www.bing.com') # GET方法
print(response.closed)
with response:
    print(1, type(response)) # http.client.HTTPResponse 类文件对象
    print(2, response.status, response.reason) # 状态
    print(3, response.geturl()) # 返回真正的URL
    print(4, response.info()) # headers
    print(5, response.read()) # 读取返回的内容

print(response.closed)
```

上例，通过urllib.request.urlopen方法，发起一个HTTP的GET请求，WEB服务器返回了网页内容。响应的数据被封装到类文件对象中，可以通过read方法、readline方法、readlines方法获取数据，status和reason属性表示返回的状态码，info方法返回头信息，等等。

User-Agent问题

上例的代码非常精简，即可以获得网站的响应数据。urlopen方法只能传递url和data这样的数据，不能构造HTTP的请求。例如useragent。
源码中构造的useragent如下

```
# urllib.request.OpenerDirector
class OpenerDirector:
    def __init__(self):
        client_version = "Python-urllib/%s" % __version__
        self.addheaders = [('User-agent', client_version)]
```

当前显示为 `Python-urllib/3.6`

有些网站是反爬虫的，所以要把爬虫伪装成浏览器。随便打开一个浏览器，复制浏览器的UA值，用来伪装。

Request类

`Request(url, data=None, headers={})`
初始化方法，构造一个请求对象。可添加一个header的字典。data参数决定是GET还是POST请求。
`add_header(key, val)` 为header中增加一个键值对。

```
from urllib.request import Request, urlopen
import random

# 打开一个url返回一个Request请求对象
```

```
# url = 'https://movie.douban.com/' # 注意尾部的斜杠一定要有
url = 'http://www.bing.com/'

ua_list = [
    "Mozilla/5.0 (Windows NT 6.1; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/57.0.2987.133 Safari/537.36",# chrome
    "Mozilla/5.0 (Windows; U; Windows NT 6.1; zh-CN) AppleWebKit/537.36 (KHTML, like Gecko)
Version/5.0.1 Safari/537.36", # safafi
    "Mozilla/5.0 (Windows NT 6.1; Win64; x64; rv:50.0) Gecko/20100101 Firefox/50.0", # Firefox
    "Mozilla/5.0 (compatible; MSIE 9.0; Windows NT 6.1; Trident/5.0)" # IE
]

ua = random.choice(ua_list) # pick one
# ua需要加到请求头中
request = Request(url)
request.add_header('User-Agent', random.choice(ua_list))
print(type(request))

response = urlopen(request, timeout=20) # request对象或者url都可以
print(type(response))

with response:
    print(1, response.status, response.getcode(), response.reason)  # 状态，getcode本质上就是返回
status
    print(2, response.geturl())  # 返回数据的url。如果重定向，这个url和原始url不一样
    # 例如原始url是http://www.bing.com/，返回http://cn.bing.com/
    print(3, response.info())  # 返回响应头headers
    print(4, response.read())  # 读取返回的内容

print(5, request.get_header('User-agent'))
print(6, 'user-agent'.capitalize())
```

urllib.parse模块

该模块可以完成对url的编解码

先看一段代码，进行编码

```
from urllib import parse

u = parse.urlencode('http://www.magedu.com/python')

# 运行结果如下
Traceback (most recent call last):
  File "C:\Python\Python35\lib\urllib\parse.py", line 780, in urlencode
    raise TypeError
TypeError

During handling of the above exception, another exception occurred:

Traceback (most recent call last):
  File "C:/Users/Administrator/PycharmProjects/classbase/test3.py", line 4, in <module>
    u = parse.urlencode('http://www.magedu.com/python')
```

```
  File "C:\Python\Python35\lib\urllib\parse.py", line 788, in urlencode
    "or mapping object").with_traceback(tb)
  File "C:\Python\Python35\lib\urllib\parse.py", line 780, in urlencode
    raise TypeError
TypeError: not a valid non-string sequence or mapping object
```

urlencode函数第一参数要求是一个字典或者二元组序列。

```
from urllib import parse

u = parse.urlencode({
    'url':'http://www.magedu.com/python',
    'p_url':'http://www.magedu.com/python?id=1&name=张三',
})
print(u)

# 运行结果如下
p_url=http%3A%2F%2Fwww.magedu.com%2Fpython%3Fid%3D1%26name%3D%E5%BC%A0%E4%B8%89&url=http%3A%2F%2
Fwww.magedu.com%2Fpython
```

从运行结果来看冒号、斜杠、&、等号、问号等符号全部被编码了，%之后实际上是单字节十六进制表示的值。

一般来说url中的地址部分，一般不需要使用中文路径，但是参数部分，不管GET还是POST方法，提交的数据中，可能有斜杆、等号、问号等符号，这样这些字符表示数据，不表示元字符。如果直接发给服务器端，就会导致接收方无法判断谁是元字符，谁是数据了。为了安全，一般会将数据部分的字符做url编码，这样就不会有歧义了。
后来可以传送中文，同样会做编码，一般先按照字符集的encoding要求转换成字节序列，每一个字节对应的十六进制字符串前加上百分号即可。

```
# 网页使用utf-8编码
# https://www.baidu.com/s?wd=中
# 上面的url编码后，如下
# https://www.baidu.com/s?wd=%E4%B8%AD

from urllib import parse

u = parse.urlencode({'wd':'中'}) # 编码
url = "https://www.baidu.com/s?{}".format(u)
print(url)

print('中'.encode('utf-8')) # b'\xe4\xb8\xad'

print(parse.unquote(u)) # 解码
print(parse.unquote(url))
```

提交方法method

最常用的HTTP交互数据的方法是GET、POST。

GET方法，数据是通过URL传递的，也就是说数据是在HTTP报文的header部分。
POST方法，数据是放在HTTP报文的body部分提交的。
数据都是键值对形式，多个参数之间使用&符号连接。例如a=1&b=abc

GET方法

连接 必应 搜索引擎官网，获取一个搜索的URL `http://cn.bing.com/search?q=马哥教育`

需求
请写程序完成对关键字的bing搜索，将返回的结果保存到一个网页文件。

```
from urllib.request import Request, urlopen
from urllib.parse import urlencode


keyword = input('>> 请输入搜索关键字 ')
data = urlencode({
    'q':keyword
})

base_url = 'http://cn.bing.com/search'
url = '{}?{}'.format(base_url, data)
print(url)

# 伪装
ua = "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"
request = Request(url, headers={'User-agent':ua})

response = urlopen(request)
with response:
    with open('o:/bing.html', 'wb') as f:
        f.write(response.read())

print('成功')
```

POST方法

http://httpbin.org/ 测试网站

```
from urllib.request import Request, urlopen
from urllib.parse import urlencode
import simplejson

request = Request('http://httpbin.org/post')
request.add_header(
    'User-agent',
    "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"
)

data = urlencode({'name':'张三,@=/&*', 'age':'6'})
```

```
print(data)

# res = urlopen(request, data='name=张三,@=/&*,&age=6'.encode()) # 不做url编码有风险
res = urlopen(request, data=data.encode()) # POST方法，Form提交数据
with res:
    print(res.read())
```

处理JSON数据

查看“豆瓣电影”，看到“最近热门电影”的“热门”

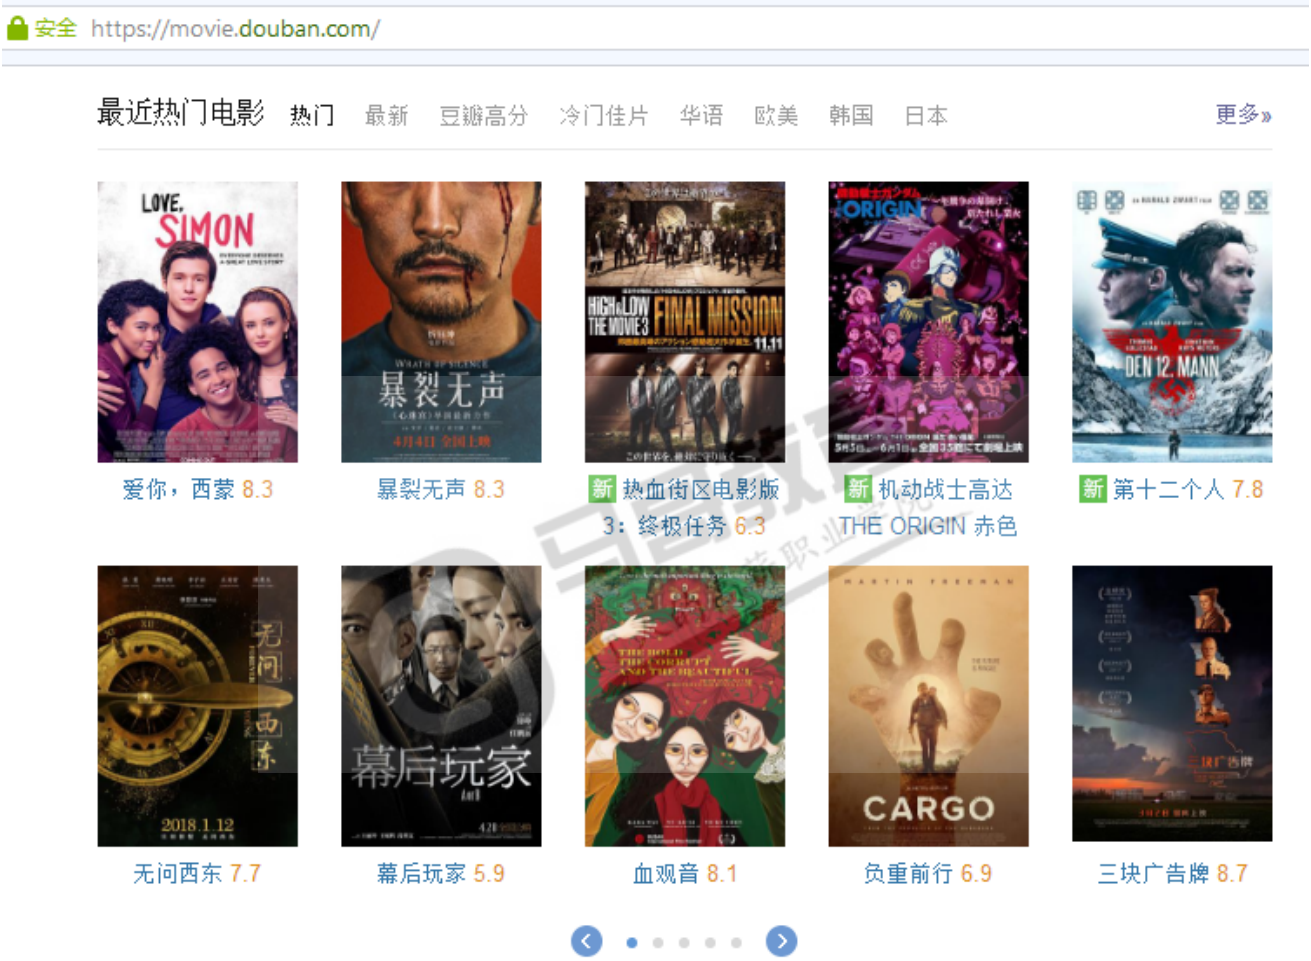

通过分析，我们知道这部分内容，是通过AJAX从后台拿到的Json数据。
访问URL是
`https://movie.douban.com/j/search_subjects?type=movie&tag=%E7%83%AD%E9%97%A8&page_limit=50&page_start=0`
`%E7%83%AD%E9%97%A8` 是utf-8编码的中文“热门”
服务器返回的Json数据如下


```
▼ subjects: [{rate: "8.3", cover_x: 4050, title: "爱你，西蒙", url: "https://movie.douban.com/subject/26654498/",…},…]
  ▶ 0: {rate: "8.3", cover_x: 4050, title: "爱你，西蒙", url: "https://movie.douban.com/subject/26654498/",…}
  ▶ 1: {rate: "8.3", cover_x: 3578, title: "暴裂无声", url: "https://movie.douban.com/subject/26647117/",…}
  ▶ 2: {rate: "6.3", cover_x: 1076, title: "热血街区电影版3：终极任务", url: "https://movie.douban.com/subject/26948060/",…}
  ▶ 3: {rate: "8.9", cover_x: 654, title: "机动战士高达THE ORIGIN 赤色彗星诞生",…}
  ▶ 4: {rate: "7.8", cover_x: 554, title: "第十二个人", url: "https://movie.douban.com/subject/26350706/",…}
  ▶ 5: {rate: "7.7", cover_x: 1750, title: "无问西东", url: "https://movie.douban.com/subject/6874741/",…}
  ▶ 6: {rate: "5.9", cover_x: 2126, title: "幕后玩家", url: "https://movie.douban.com/subject/26774033/",…}
  ▶ 7: {rate: "8.1", cover_x: 1863, title: "血观音", url: "https://movie.douban.com/subject/27113517/",…}
```


轮播组件，共需要50条数据。

https://movie.douban.com/j/search_subjects?type=movie&tag=%E7%83%AD%E9%97%A8&page_limit=50&page_start=0

tag 标签“热门”，表示热门电影
type 数据类型，movie是电影
page_limit 表示返回数据的总数
page_start 表示数据偏移

```
from urllib.request import Request, urlopen
from urllib.parse import urlencode

url = 'https://movie.douban.com/j/search_subjects'

request = Request(url)
request.add_header(
    'User-agent',
    "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75 Safari/537.36"
)

data = urlencode({
    'type':'movie',
    'tag':'热门',
    'page_limit':10,
    'page_start':10
})

# POST方法
res = urlopen(request, data=data.encode())
with res:
    print(res._method)
    print(res.read().decode())

# GET方法
with urlopen('{}?{}'.format(url, data)) as res:
    print(res._method)
    print(res.read().decode())
```

HTTPS证书忽略

HTTPS使用SSL安全套接层协议，在传输层对网络数据进行加密。HTTPS使用的时候需要证书，而证书需要CA认证。

CA(Certificate Authority)是数字证书认证中心的简称，是指发放、管理、废除数字证书的机构。
CA是受信任的第三方，有CA签发的证书具有可信性。如果用户由于信任了CA签发的证书导致的损失，可以追究CA的法律责任。
CA是层级结构，下级CA信任上级CA，且有上级CA颁发给下级CA证书并认证。

一些网站，例如淘宝，使用HTTPS加密数据更加安全。

```
from urllib.request import Request, urlopen

# request = Request('http://www.12306.cn/mormhweb/') # 可以访问
# request = Request('https://www.baidu.com/') # 可以访问
request = Request('https://www.12306.cn/mormhweb/') # 报SSL认证异常
request.add_header(
    'User-agent',
    "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"
)

# ssl.CertificateError: hostname 'www.12306.cn' doesn't match either of ......
with urlopen(request) as res:
    print(res._method)
    print(res.read())
```

通过HTTPS访问12306的时候，失败的原因在于12306的证书未通过CA认证，它是自己生成的证书，不可信。而其它网站访问，如`https://www.baidu.com/`并没有提示的原因，它的证书的发行者受信任，且早就存储在当前系统中。

能否像浏览器一样，忽略证书不安全信息呢？

```
from urllib.request import Request, urlopen
import ssl # 导入ssl模块


# request = Request('http://www.12306.cn/mormhweb/') # 可以访问
# request = Request('https://www.baidu.com/') # 可以访问
request = Request('https://www.12306.cn/mormhweb/') # 报SSL认证异常
request.add_header(
    'User-agent',
    "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"
)

# 忽略不信任的证书
context = ssl._create_unverified_context()

res = urlopen(request, context=context)
# ssl.CertificateError: hostname 'www.12306.cn' doesn't match either of ......
with res:
    print(res._method)
    print(res.geturl())
    print(res.read().decode())
```

urllib3库

https://urllib3.readthedocs.io/en/latest/
标准库urllib缺少了一些关键的功能，非标准库的第三方库urllib3提供了，比如说连接池管理。

安装
`$ pip install urllib3`

```
import urllib3

# 打开一个url返回一个对象
url = 'https://movie.douban.com/'

ua = "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"

# 连接池管理器
with urllib3.PoolManager() as http:
    response = http.request('GET', url, headers={
        'User-Agent':ua
    })
    print(type(response))
    print(response.status, response.reason)
    print(response.headers)
    print(response.data)
```

requests库 **

requests使用了urllib3，但是API更加友好，推荐使用。

```
import requests

ua = "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"
url = 'https://movie.douban.com/'

response = requests.request('GET', url, headers={'User-Agent':ua})
with response:
    print(type(response))
    print(response.url)
    print(response.status_code)
    print(response.request.headers) # 请求头
    print(response.headers) # 响应头
    print(response.text[:200]) # HTML的内容
    with open('o:/movie.html','w', encoding='utf-8') as f:
        f.write(response.text) # 保存文件，以后备用
```

requests默认使用Session对象，是为了在多次和服务器端交互中保留会话的信息，例如cookie。

```
# 直接使用Session
import requests

ua = "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/55.0.2883.75
Safari/537.36"

urls = ['https://www.baidu.com/s?wd=magedu', 'https://www.baidu.com/s?wd=magedu']
session = requests.Session()
with session:
```

```
    for url in urls:
        response = session.get(url, headers={'User-Agent':ua})

        with response:
            print(type(response))
            print(response.url)
            print(response.status_code)
            print(response.request.headers) # 请求头
            print(response.cookies) # 响应的cookie
            print(response.text[:20]) # HTML的内容
```