
# Scrapy-redis组件

## 概述

这是一个能给Scrapy框架引入分布式的组件。 分布式由Redis提供,可以在不同节点上运行爬虫,共用同一个Redis实例。 在Redis中存储待爬取的URLs、Items。



\$ pip install scrapy-redis

#### 安装要求

安装

Python 2.7, 3.4 or 3.5 Redis >= 2.8 Scrapy >= 1.0

redis-py >= 2.10

## 配置

```
# Enables scheduling storing requests queue in redis.
SCHEDULER = "scrapy_redis.scheduler.Scheduler"

# Ensure all spiders share same duplicates filter through redis.
DUPEFILTER_CLASS = "scrapy_redis.dupefilter.RFPDupeFilter"

# Store scraped item in redis for post-processing.
ITEM_PIPELINES = {
    'scrapy_redis.pipelines.RedisPipeline': 300
}
```

```
# The item pipeline serializes and stores the items in this redis key.
# 这个key很重要
#REDIS_ITEMS_KEY = '%(spider)s:items'

# Specify the host and port to use when connecting to Redis (optional).
#REDIS_HOST = 'localhost'
#REDIS_PORT = 6379

# Default start urls key for RedisSpider and RedisCrawlSpider.
#REDIS_START_URLS_KEY = '%(name)s:start_urls'
```

#### 在以下方面做了增强

Scheduler + Duplication Filter, Item Pipeline, Base Spiders

- Scheduler 本质上将原来的普通队列,变成了redis以提供多爬虫多进程共享,并行能力增强。
- Duplication Filter scrapy使用set来去重, scrapy-redis使用redis的set类型去重
- Item Pipeline 在Item Pipeline增加一个处理,即将数据items存入redis的items queue中
- Base Spiders
   提供了使用了RedisMixin的RedisSpider和RedisCrawlSpider,从Redis中读取Url。

Redis是服务,爬虫就是它的客户端,客户端就可以扩展出并行的很多爬虫一起爬取。

# redis安装

这里不再赘述。

# 豆瓣影评分析项目

# 抓取内容分析

抓取最新top 1电影,分析其影评

豆瓣电影

搜索电影、电视剧、综艺、影人

影讯&购票

选电影 电视剧 排行榜

分类

2017年度榜单

2017观影报告

正在热映

全部正在热映》

即将上映»







\*\*\*\* 7.5 选座购票

蚁人2:黄蜂...



曹操与杨修 🛅

暂无评分

选座购票



一出好戏

\*\*\*\* 7.3

选座购票

人的商新取



巨齿鲨

\*\*\*\* 6.0

选座购票



快把我哥带走...

\*\*\*\*\* 7.0

选座购票

点击"全部正在热映", 跳转至 https://movie.douban.com/cinema/nowplaying/beijing/。

# 电影票 - 北京 阿姆城市

#### 正在上映



蚁人2:黄蜂女... \*\*\*\*\*7.5

选座购票



曹操与杨修 🛅

暂无评分

选座购票



一出好戏 \*\*\*\*\*7.3

选座购票



巨齿鲨 \*\*\*\*\* 6.0

选座购票



快把我哥带走 \*\*\*\*\* 7.0

选座购票

这部分内容是直接通过网页HTML返回的,提取影片id的xpath为 //div[@id="nowplaying"]//li[1]/@id

#### 影片页

点击电影,出现影片主题页面 https://movie.douban.com/subject/26636712/ ,在页面下面的短评处点击"全部(n) 条"进入影片评论页面,从而得到影评的链接 https://movie.douban.com/subject/26636712/comments? start=20&limit=20

测试发现,只有start有用,limit不能控制返回的条目数

start测试到220时,发现不能返回数据了。其实很多网站都有这种策略,显示的数据可能有很多页,但是人一般不可能看那么多页,能看查回来的10页结果就不错了。

#### 提取影评的xpath

//div[@class="comment-item"]//span[@class="short"]

# 创建Scrapy项目

\$ scrapy startproject review moviereview

### 配置

使用scrapy-redis,配置如下

```
BOT_NAME = 'review'
SPIDER_MODULES = ['review.spiders']
NEWSPIDER_MODULE = 'review.spiders'
USER_AGENT = "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/55.0.2883.75 Safari/537.36"
# Enables scheduling storing requests queue in redis.

SCHEDULER = "scrapy_redis.scheduler.Scheduler"

# Ensure all spiders sho
DUPEFILTER_CLASS = "scrapy_redis.dupefilter.RFPDupeFilter"
# Don't cleanup redis queues, allows to pause/resume crawls.
#SCHEDULER PERSIST = True
# The item pipeline serializes and stores the items in this redis key.
#REDIS_ITEMS_KEY = '%(spider)s:items'
#ITEM PIPELINES = {
     'review.pipelines.ReviewPipeline': 300,
#
     'scrapy_redis.pipelines.RedisPipeline': 300
#}
# Specify the host and port to use when connecting to Redis (optional).
REDIS_HOST = 'localhost'
REDIS_PORT = 6379
#LOG_LEVEL = 'DEBUG'
```

## 构建Item

```
import scrapy

class ReviewItem(scrapy.Item):
    review = scrapy.Field()
```

## 构建爬虫

\$ scrapy genspider -t crawl dbreview douban.com

写完先测试,然后将类型改为RedisCrawlSpider

```
import scrapy
from scrapy.linkextractors import LinkExtractor
from scrapy.spiders import CrawlSpider, Rule
from ..items import ReviewItem
from scrapy_redis.spiders import RedisCrawlSpider
class DbreviewSpider(RedisCrawlSpider): # scrapy-redis的类
    name = 'dbreview'
    allowed_domains = ['douban.com']
    #start_urls = ['https://movie.douban.com/subject/26636712/comments?start=0&limit=20']
    """Spider that reads urls from redis queue (myspider:start_urls)."""
    redis key = 'dbreview:start urls'
    rules = (
        Rule(LinkExtractor(allow=r'start=\d+'), callback='parse_item', follow=False),
    def parse_item(self, response):
        print('-'*30)
        comment = '//div[@class="comment-item"]//span[@class="short"]/text()'
        reviews = response.xpath(comment).extract()
        for review in reviews:
            item = ReviewItem()
            item['review'] = review.strip()
            yield item
```

### 爬取

```
$ scrapy crawl dbreview
```

会发现程序会卡住,这是因为在等待起始URL

### 手动添加开始url

redis中

## 分析

使用爬虫,爬取所有数据,然后使用redis中的数据开始分析

### jieba分词

安装 pip install jieba

官网 https://github.com/fxsiv/jieba

测试代码

```
# encoding=utf-8
import jieba

seg_list = jieba.cut("我来到北京清华大学", cut_all=True)
print("Full Mode: " + "/ ".join(seg_list)) # 全模式

seg_list = jieba.cut("我来到北京清华大学", cut_all=False)
print("Default Mode: " + "/ ".join(seg_list)) # 精确模式

seg_list = jieba.cut("他来到了网易杭研大厦") # 默认是精确模式
print(", ".join(seg_list))

seg_list = jieba.cut("他来到了网易杭研大厦") # 數基積額模式
print(", ".join(seg_list))

s = jieba.lcut("他来到了网易杭研大厦") # 直接返回列表
print(s)

s = jieba.cut("他来到了网易杭研大厦") # 返回生成器
print(s)
```

## stopword 停用词

数据清洗:把脏数据洗掉。检测出并去除掉数据中无效或无关的数据。例如,空值、非法值的检测,重复数据检测等。

对于一条条影评来说,我们分析的数据中包含了很多无效的数据,比如标点符号、英文的冠词、中文"的"等等,需要把它们清除掉。

使用停用词来去除这些无效的数据。

### wordcloud词云

https://amueller.github.io/word\_cloud/index.html

依赖numpy、matplotlib

pip install wordcloud

#### 常用方法

方法	说明
fit_words(frequencies)	Create a word_cloud from words and frequencies.
generate(text)	Generate wordcloud from text.
generate_from_frequencies(frequencies[,])	Create a word_cloud from words and frequencies
generate_from_text(text)	Generate wordcloud from text
process_text(text)	Splits a long text into words, eliminates the stopwords
recolor([random_state, color_func, colormap])	Recolor existing layout
to_array()	Convert to numpy array
to_file(filename)	Export to image file

```
from redis import Redis
import json
import jieba
redis = Redis()
stopwords = set()
with open('chineseStopWords.txt', encoding='gbk') as f:
   for line in f:
       print(line.rstrip('\r\n').encode())
       stopwords.add(line.rstrip('\r\n'))
print(len(stopwords))
print(stopwords)
items = redis.lrange('dbreview:items', 0, -1)
print(type(items))
words = \{\}
for item in items:
   val = json.loads(item)['review']
   for word in jieba.cut(val):
       words[word] = words.get(word, 0) + 1
print(len(words)) # 829
print(sorted(words.items(), key=lambda x:x[1], reverse=True))
#[(',',119),('的',73),('。',55),('了',42),('是',23),('',22),('人',19),
#('也', 19),('和', 16),('彩蛋', 16),('!', 15),('反派', 13),
#('蚁', 13),('在', 12),('我', 12),('都', 12),('被', 11),('很', 11),('好', 10)
words = \{\}
for item in items:
```

```
val = json.loads(item)['review']
   for word in jieba.cut(val):
        if word not in stopwords:
            words[word] = words.get(word, 0) + 1
total = len(words)
print(total)
frenq = {k:v/total for k,v in words.items()}
print(sorted(frenq.items(), key=lambda x:x[1], reverse=True))
from wordcloud import WordCloud
import matplotlib.pyplot as plt
wordcloud = WordCloud(font_path='simhei.ttf', background_color='white',
                     max_font_size=80)
plt.figure(2)
wordcloud.fit_words(freng)
plt.imshow(wordcloud)
plt.axis('off') # 去掉坐标系
plt.show()
```